CodexAI — Document Intelligence & Hybrid RAG

Кроссплатформенный клиент локального парсинга документов, камерного Vision OCR и потокового ИИ-анализа.

Стек: Flutter 3.35 • Feature-First Clean Architecture • flutter_riverpod 2.6 • Drift SQLite • Gemini 3.5 Flash SSE

Репозиторий: github.com/ShadowNoYami/CodexAI

Узкие места стандартных ИИ-чатов при работе с файлами до 100 МБ

1. Переполнение окна контекста: передача документов > 120 000 токенов вызывает HTTP 400 / 429.

2. Ответы без верификации: отсутствие строгой привязки к pageNumber и chunkIndex.

3. Блокировка UI Event Loop: фризы интерфейса при синхронном чтении тяжелых PDF/DOCX в главном потоке.

Четырехфазный конвейер обработки документа

STEP 01 (INGEST): FilePickerService + ImagePicker — проверка Magic Bytes (%PDF, PK\x03\x04) и съемка с камеры.

STEP 02 (ISOLATE): DocumentParserService + ImageOcrService — парсинг в Isolate через TransferableTypedData и Vision OCR.

STEP 03 (RETRIEVAL): RagRetrieverService — адаптивный выбор Full-Context (<=30K ток.) или Hybrid RAG (BM25 + Cosine).

STEP 04 (STREAM): SseStreamTransformer + MessageBubble — потоковый вывод токенов и кликабельные цитаты CitedSource.

Feature-First Clean Architecture (Presentation / Domain / Data)

PRESENTATION: ActiveChatNotifier, DocumentsNotifier, ChatSessionsNotifier, MainChatScreen, DocumentPreviewModal.

DOMAIN: DocumentEntity, DocumentChunkEntity, ChatMessageEntity, CitedSource, AnalysisMode, SystemPrompts.

DATA & CORE: AppDatabase (Drift SQLite), LlmRemoteDataSource, RagRetrieverService, IsolateRunner, TokenEstimator.

Zero-Copy парсинг в Isolate и мультимодальный Vision OCR

PDF с текстовым слоем: постраничное извлечение через Syncfusion PdfTextExtractor.

Скан-PDF без текста (ScannedPdfException): автоизвлечение встроенных JPEG (FF D8..FF D9) -> Gemini Vision OCR.

Камера и галерея телефона (JPG/PNG): распознавание текста, печатей и таблиц в формат Markdown.

Семантический чанкинг TextChunkerService: chunkSize = 3200 символов, overlap = 600 символов.

Матрица режимов работы ИИ (SystemPrompts)

AnalysisMode.qa: ответ строго по тегам <source file page chunk> с обязательной ссылкой [Файл, Стр. X].

AnalysisMode.executiveSummary: структурированная выжимка (1. TL;DR, 2. Тезисы, 3. Цифры и даты, 4. Выводы).

AnalysisMode.deepAnalysis: сводная Markdown-таблица метрик, поиск противоречий между главами и карта рисков.

State Management (Riverpod) и SSE Streaming

Поток байтов Dio (ResponseType.stream) декодируется через SseStreamTransformer.

Состояния ChatGenerationStatus: idle -> loading (RAG выборка) -> streaming (токены в реальном времени).

Поддержка принудительной остановки генерации через CancelToken и повтора запроса retryLastMessage().

Адаптивный интерфейс MainChatScreen (Material 3 Light & Dark)

ChatSidebar: постоянная панель на Desktop/Web (>=860px) и выдвижной Drawer на мобильных экранах.

MessageBubble: рендеринг таблиц Markdown, копирование кода и переход к странице документа по клику на цитату.

DocumentPreviewModal: поиск по чанкам и страницам, статистика токенов и просмотр полного текста.

Инженерные гарантии производительности и отказоустойчивости

120K Tokens Budget: TokenEstimator.trimHistoryToBudget (12K на историю) и fitChunksToBudget.

60/120 FPS UI: неблокирующая обработка файлов до 100 МБ в фоновом изоляте.

3x Model Fallback: автопереключение gemini-3.5-flash -> gemini-3.8-flash -> gemini-3-flash-preview при HTTP 404/503.

Статус готовности и дорожная карта масштабирования

Готовность: 8/8 тестов (flutter test), 0 ошибок анализатора (flutter analyze), опубликовано на GitHub.

Шаг 1: Полнотекстовый индекс SQLite FTS5 внутри таблиц Drift.

Шаг 2: Пакетная векторизация gemini-embedding-001 для многотысячных архивов.

Шаг 3: Прямой экспорт аналитических отчетов и таблиц в PDF / DOCX.